



Implementace a prolomení Afinitní šifry

KRY - Kryptografie

1 Úvod

Tento projekt se věnuje implementaci a prolomení substituční šifry, konkrétně Afinitní šifry, která se používá k šifrování textových zpráv. Její základní princip spočívá v lineární transformaci jednotlivých písmen v textu. Tento program umí šifrovat, dešifrovat a prolamovat tuto šifru. Afinitní šifra se skládá ze dvou klíčů "a" a "b".

2 Implementace

Zdrojový kód je členěn na soubory podle jejich funkce následujícím způsobem:

- main.cpp/hpp - Hlavní soubor, který parsuje vstupní argumenty, kontroluje korektnost konfigurace a následně volá jednotlivé moduly programu.
- decrypt.cpp/hpp - Dešifrovací modul
- encrypt.cpp/hpp - Šifrovací modul
- break.cpp/hpp - Modul na prolamování šifry
- myLib.cpp/hpp - Obecné, pomocné funkce programu
- config.hpp - Struktura konfigurace
- externalCode.cpp/hpp - Převzaté funkce a konstrukty.

2.1 Šifrování/dešifrování


Šifrování/dešifrování probíhá velmi podobně. Šifrování probíhá znak po znaku. V prvním kroku se znak (a-Z) převede do normalizované formy (interval 0-25). Poté je znak transformován pomocí odpovídající funkce. Takto substituovaný znak je následně zpětně denormalizován a přiveden na výstup. Znaky, které nelze šifrovat (mezery, čísla, atd.), se nešifrují a jsou ponechány v nezměněné podobě.

2.2 Prolamování šifry

Při prolamování zašifrovaného textu bez znalosti klíče, jsem využil dvou statistických znalostí textu. První znalostí byla relativní četnost jednotlivých znaků v průměrném českém textu. Druhou znalostí byl seznam 40 nejčastějších bigramů (dvojic písmen) vyskytujících se v českém textu.

Vzhledem k malému počtu substituční funkcí 328 (klíč A může nabýt 13 hodnot a klíč B 26 hodnot - $13 \cdot 26 = 328$) jsem se rozhodl prozkoumávat všechny kombinace klíčů. Každou kombinaci klíčů jsem algoritmicky ohodnotil metrikou. Za výsledný klíč byl prohlášen takový pár, který měl nejmenší metriku.

Výpočet první části metriky proběhl následovně: V zašifrovaném textu jsem spočetl četnosti všech znaků. Poté jsem každý znak abecedy zašifroval zkoumaným párem klíčů. Provedl jsem rozdíl četnosti tohoto znaku v luštěném textu s průměrnou četností v českém jazyce (viz. obr. 1). Tento rozdíl jsem následně umocnil dvěma a přičetl k metrice. Myšlenka spočívala, že pokud se jednalo o správnou substituci, byl rozdíl četností velmi malý a proto se metrika moc nezvýšila. Pokud rozdíl četností byl velký, metrika se podstatně zvýšila. Umocnění na druhou mocninou ještě více zvýraznilo rozdíly četností.



Obrázek 1: Graf četnosti písmen v Českém jazyce (převzato z [2]).

Tato první metrika se ukázala být dobrou, hledaný klíč se obvykle nacházel mezi top 10 klíči s nejlepší metrikou. Zhruba u poloviny případů byl nejlépe ohodnocený klíč hledaným klíčem.

Druhou část metriky tvořila analýza bigramů. V zašifrovaném textu jsem spočítal všechny jednotlivé bigramy. Poté jsem z této analýzy vyňal 50 nejčastějších bigramů. Následně jsem šifroval nejčastějších 40 bigramů v českém jazyce (viz. obr. 2) právě zkoumaným párem klíčů, takto zašifrované bigramy jsem se pokoušel nalézt v těchto 50 nejčastějších bigramech. V případě, že bigram nebyl nalezen, byla páru klíčů udělena penalta. V opačné případě metrika nebyla navýšena.

st	74285	en	50645	le	38926	to	36355	ho	31442	al	29682	př	27885	em	26818
35191	do	30665	ed	29622	at	27603	in	26427	ní	60525	na	46737	ko	38688	ou
3	ne	38671	no	32612	os	30530	an	29326	ře	27181	sk	26085	po	56239	je
4243	7168	lo	25981	ov	53818	pr	42099	od	38393	la	32336	se	30454	ce	28280
er	2	ro	51961	te	40393	ra	37531	li	31952	ta	30177	va	27987	ti	26858
ně	25739														

Obrázek 2: Nejčastější bigramy v českém jazyce (převzato z [1]).

Obě zmíněné metriky byly použity s rovnou váhou (1:1). Byť je tento přístup poměrně "těžkotonážní", v rámci testování se k mému překvapení ukázal jako extrémně spolehlivý, odolný proti menším abnormalitám v luštěném textu a funkční i s malým vzorkem zkoumaného textu. I když program zkoumá všechny varianty klíčů, při testování jsem nezaznamenal výkonnostní problémy.

Program navíc vypíše na chybový výstup dalších 10 klíčů s největšími metrikami, pro případ, že byla první shoda chybná.

3 Zhodnocení

Podle mého zhodnocení byl projekt úspěšně vypracován v plném rozsahu, nedostatků jsi nejsem vědom.

Odkazy

- [1] Centrum zpracování přirozeného jazyka. *Frekvence písmen, bigramů, trigramů, délka slov*. URL: <https://nlp.fi.muni.cz/cs/FrekvenceSlovLemmat>. (navštíveno: 8.3.2023).
- [2] Jan Neckář. *Četnost znaků v českém textu*. URL: <https://algoritmy.net/article/40/Cetnost-znaku-CJ>. (navštíveno: 8.3.2023).